

Пример TF-IDF (Входные данные)

Задача:

У нас есть три документа, которые описывают различные аспекты информационной безопасности.

Мы хотим рассчитать TF-IDF для термина "атака".

Данные:

1. Документ 1:

"Атака на сервер была успешно отражена благодаря обновлению системы безопасности."

2. Документ 2:

"Система безопасности предотвращает кибератаки и защищает данные."

3. Документ 3:

"Обновление системы устранило уязвимость для предотвращения атак."

Шаги расчета:

1. Подсчет TF (частота термина) для слова "атака" в каждом документе:

- Документ 1:

Общее количество слов = 10. Слово "атака" встречается 1 раз.

$$TF1 = 1/10 = 0.1$$

- Документ 2:

Общее количество слов = 8. Слово "атака" не встречается.

$$TF2 = 0/8 = 0$$

- Документ 3:

Общее количество слов = 9. Слово "атака" встречается 1 раз.

$$TF3 = 1/9 \approx 0.111$$

2. Подсчет IDF (обратная частота документа):

Всего документов $N=3$. Слово "атака" встречается в 2 из 3 документов ($n=2$).

Формула:

$$IDF = \log \frac{N}{n} = \log \frac{3}{2} \approx 0.176$$

3. Расчет TF-IDF:

$TF\ IDF = TF \times IDF$

- Для Документа 1:
 $TF\ IDF_1 = 0.1 \times 0.176 \approx 0.0176$
- Для Документа 2:
 $TF\ IDF_2 = 0 \times 0.176 = 0$
- Для Документа 3:
 $TF\ IDF_3 = 0.111 \times 0.176 \approx 0.0195$

Результаты:

- Значение TF-IDF для термина "атака":
 - Документ 1: 0.0176
 - Документ 2: 0
 - Документ 3: 0.0195

Термин "атака" более значим для Документа 3, чем для Документа 1, и не имеет значения для Документа 2. Это может быть полезно для анализа и классификации текстов, связанных с кибератаками.